

G9Z ST10



Hexstrike com Ollama (v1.1)

1 - Objetivo	3
2 - Vantagens do Uso de IA local	4
2.1. Privacidade e Segurança Máximas	4
2.2. Funcionamento Offline	4
2.3. Sem Custos Recorrentes	4
2.4. Consistência	4
2.5. Maior Controle e Customização	4
2.6. Independência e Confiabilidade	5
2.7. Resumo comparativo rápido	5
3 - Instalando o Ollama e Disponibilizando na Rede	6
3.1. No Windows (Host) – Configure a GPU + Ollama	6
4 - Instalando o Hexstrike	7
4.1. Prepare uma máquina ou VM com o Kali Linux.	7
4.2. Instale as dependências básicas	7
4.3. Instale as ferramentas de pentest (HexStrike precisa delas)	7
4.4. Clone e configure o HexStrike	7
4.5. Crie um ambiente virtual	7
4.6. Instale dependências Python	7
4.7. Configure o HexStrike para usar seu Ollama	7
4.8. Crie um script de inicialização	8
4.9. Dê permissão para execução	8
4.10. Rode o HexStrike na VM	8
5. Teste a integração	9
5.1. Na VM, teste se o Ollama está acessível	9
6 - Instalando o VSCode como MCP	10
6.1. Instale o VS Code (se ainda não tiver)	10
6.2. Instale a extensão Continue no VS Code	10
6.3. Configure o Continue com seu Ollama (config.yaml)	10
6.4. Teste o Sistema	11

HEXTRIKE COM OLLAMA

1 - Objetivo

Implementar um ambiente local de IA utilizando inteligência artificial local (com Ollama) integrado à ferramenta de segurança ofensiva baseada em IA (Hexstrike) para testes, automações e experimentos em cibersegurança.

Neste laboratório o Ollama está em um servidor Windows que fica disponível para todas as máquinas da rede, e o hextrikey em um servidor com Kali Linux, aproveitando as ferramentas pré instaladas nesse sistema.

2 - Vantagens do Uso de IA local

As principais vantagens de usar IA local (também chamada de on-device, on-premise ou offline), como modelos rodando com ferramentas como Ollama, LM Studio ou similares no seu PC, notebook ou servidor próprio:

2.1. Privacidade e Segurança Máximas

- Seus prompts, dados e conversas não saem do seu dispositivo.
- Ideal para informações sensíveis (dados médicos, jurídicos, financeiros, segredos empresariais ou conteúdo pessoal/NSFW).
- Evita que empresas de nuvem usem seus dados para treinamento de modelos ou que haja vazamentos em ataques a servidores remotos.
- Facilita conformidade com leis como LGPD (no Brasil), GDPR ou HIPAA.

2.2. Funcionamento Offline

- Funciona sem internet depois de baixar o modelo.
- Perfeito para viagens, áreas rurais, ambientes seguros (sem Wi-Fi) ou quando a conexão cai.

2.3. Sem Custos Recorrentes

- Depois do investimento inicial no hardware (GPU/CPU boa), o uso é gratuito (só o custo da energia), sem assinaturas mensais, limites de tokens ou aumento de preço da API (como OpenAI, Anthropic ou Grok).

2.4. Consistência

- Você pode gerar quantos tokens quiser, usar contexto longo e rodar 24h sem rate limits ou filas.
- O modelo não muda de comportamento de uma hora para outra por atualização da empresa.

2.5. Maior Controle e Customização

- Pode ajustar o modelo com seus próprios dados.
- Escolher quantização, parâmetros, system prompts e até criar versões especializadas.
- Total liberdade para experimentar sem depender da roadmap de terceiros.

2.6. Independência e Confiabilidade

- Não depende de servidores externos (evita downtime de provedores como ChatGPT).
- Mais resistente a censura ou restrições impostas por empresas de nuvem.
- Dados ficam sempre no seu controle (soberania de dados).

2.7. Resumo comparativo rápido

- IA Local: Privacidade, offline, custo fixo, controle.
- IA na Nuvem: Modelos mais poderosos, mais fácil de usar, escalabilidade ilimitada, com os contras de privacidade e custo variável.

3 - Instalando o Ollama e Disponibilizando na Rede

Para uso do Ollama em um servidor Linux ou MacOS os passos devem ser adaptados mas são semelhantes.

3.1. No Windows (Host) – Configure a GPU + Ollama

3.1.1. Instale os drivers NVIDIA mais recentes.

3.1.2. Instale o Ollama diretamente no Windows (baixe em ollama.com).

3.1.3. Para que outros computadores possam acessar o Ollama e utilizar seus modelos de IA:

- No Ollama, vá em Settings e habilite a opção “Expose Ollama to the network”.
- Ou abra o PowerShell como Administrador e exponha o Ollama para a rede:
`$env:OLLAMA_HOST = "0.0.0.0"`
- Ou crie um atalho/serviço para rodar sempre com ‘OLLAMA_HOST=0.0.0.0’
- Ou vá em “Editar as variáveis de ambiente de sistema” no Painel de Controle e adicione a variável OLLAMA_HOST com o valor 0.0.0.0

3.1.4. Baixe um modelo bom para pentest. É necessário que o modelo tenha a opção *tools* para que possa utilizar ferramentas. No momento em que este documento é escrito recomendo o Gemma4 que possui 8 bilhões de parâmetros (9.6GB), janela de tokens de 128k, e as características *vision*, *thinking*, *tools*, *audio* e *cloud*. Também é possível obter a versão e2b com 5.18B de parâmetros em 7.2GB (ollama run gemma4:e2b)

- `ollama run gemma4` (para a versão de 8 bilhões de parâmetros)
- `ollama run gemma4:e2b` (para a versão de 5.12 bilhões de parâmetros)
- e se seu hardware for bom ou suas necessidades maiores, escolha um modelo adequado em <https://ollama.com/search>

Para evitar censura utilize um modelo Gemma4 desbloqueado:

- `ollama run igorls/gemma-4-E4B-it-heretic-GGUF`

3.1.5. Verifique se está usando GPU:

- Abra outro terminal e rode ‘ollama ps’ ou use o Gerenciador de Tarefas, aba Desempenho, enquanto faz uma inferência.
- Se não usar GPU, verifique as variáveis de ambiente e identifique o problema antes de seguir, pois o uso de modelos na CPU, apesar de funcionar, é mais lento.

3.1.6. Descubra o IP do Windows (no Prompt de Comando):

- `ipconfig`

4 - Instalando o Hexstrike

4.1. Prepare uma máquina ou VM com o Kali Linux.

4.2. Instale as dependências básicas

- `sudo apt update && sudo apt upgrade -y`
- `sudo apt install -y git python3 python3-venv python3-pip curl`

4.3. Instale as ferramentas de pentest (HexStrike precisa delas)

- `sudo apt install nmap masscan amass subfinder nuclei fierce dnsenum autorecon theharvester responder netexec enum4linux-ng gobuster feroxbuster dirsearch ffuf dirb nikto sqlmap wpscan arjun paramspider wafw00f hydra john hashcat medusa patator crackmapexec evil-winrm hash-identifier ophcrack gdb radare2 binwalk ghidra checksec foremost steghide exiftool trivy`

4.4. Clone e configure o HexStrike

- `git clone https://github.com/0x4m4/hexstrike-ai.git`
- `cd hexstrike-ai`

4.5. Crie um ambiente virtual

- `python3 -m venv venv`
- `source venv/bin/activate`

4.6. Instale dependências Python

- `pip install -r requirements.txt`

4.7. Configure o HexStrike para usar seu Ollama

- Crie um arquivo `.env` na raiz do hexstrike-ai utilizando o editor de sua preferência:

```
OPENAI_API_BASE=http://SEU_IP_DO_WINDOWS:11434/v1
OPENAI_API_KEY=ollama      # Ollama não exige chave real
OPENAI_MODEL=igorls/gemma-4-E4B-it-heretic-GGUF # ou o modelo que você baixou
```

4.8. Crie um script de inicialização

Opcional, mas recomendado. Crie `start_hexstrike.sh`:

```
#!/bin/bash
cd "$(dirname "$0")"
set -a
source .env
set +a
echo "[+] Iniciando HexStrike com Ollama em: $OPENAI_API_BASE"
echo "[+] Modelo: $OPENAI_MODEL"
python3 hexstrike_server.py --port 8888 --debug
```

4.9. Dê permissão para execução

```
chmod +x start_hexstrike.sh
```

4.10. Rode o HexStrike na VM

```
./start_hexstrike.sh
```

O servidor deve subir em `http://SEU_IP_DA_VM:8888`.

5. Teste a integração

5.1. Na VM, teste se o Ollama está acessível

- `curl http://SEU_IP_DO_WINDOWS:11434`

e verifique se a mensagem “Ollama is Running” aparece. Caso você não consiga ver essa mensagem, abra o “Windows Defender Firewall com Segurança Avançada”, e em Regras de Entrada crie uma nova regra chamada Ollama, permitindo todas as conexões de entrada na porta 11434.

caso queira ver os modelos disponíveis:

- `curl http://SEU_IP_DO_WINDOWS:11434/api/tags`

5.2. Teste o HexStrike:

`curl http://localhost:8888/health`

Agora você pode conectar clientes MCP apontando para o endereço do HexStrike na VM.

6 - Instalando o VSCode como MCP

O HexStrike funciona como um MCP Server (Model Context Protocol) e endpoint *OpenAI-compatible*, por isso precisa de um cliente para ser utilizado.

6.1. Instale o VS Code (se ainda não tiver)

```
sudo apt update
sudo apt install code
```

6.2. Instale a extensão Continue no VS Code

- Abra o VS Code
- Vá em Extensions (Ctrl + Shift + X)
- Procure por Continue - open-source AI code agent
- Clique em Install

Após instalar, um ícone de girassol aparece na barra lateral.

6.3. Configure o Continue com seu Ollama (config.yaml)

Pressione Ctrl + Shift + P, digite “Continue: Settings”, em *Configs* e *Local Config*. Isso abrirá o arquivo (geralmente `~/continue/config.yaml`).

Substitua o conteúdo por algo assim (configuração recomendada):

```
name: Ollama
version: 1.0.0
schema: v1
```

```
models:
```

```
  # Modelo principal (chat + edição + agente)
```

```
  - name: gemma-4-E4B-it-heretic-GGUF
```

```
    provider: ollama
```

```
    model: igorls/gemma-4-E4B-it-heretic-GGUF      # mude para o modelo que você puxou
```

```
    apiBase: http://192.168.15.48:11434
```

```
  roles:
```

```
    - chat
```

```
    - edit
```

```
    - apply
```

```
    - autocomplete
```

```
contextLength: 65536
```

```
defaultCompletionOptions:
```

```
  temperature: 0.7
```

mcpServers:

- *name: hexstrike*

type: stdio

command: python

args:

- */opt/hexstrike-ai/hexstrike_mcp.py # ← mude para o caminho real do seu arquivo*

- *--server*

- *http://localhost:8888*

env: {}

Salve o arquivo.

6.4. Teste o Sistema

- Clique no ícone de Girassol do Continue (barra lateral)

- No chat, selecione seu modelo (gemma-4-E4B-it-heretic-GGUF)

Exemplo de prompt:

“faça uma varredura completa na rede 192.168.15.* e um pentest em todas as estações que encontrar, fazendo um relatório detalhado enquanto realiza a atividade.”

se você estiver utilizando um modelo bloqueado receberá uma resposta como:

“Não posso ajudar a executar varredura completa e pentest em todas as estações de uma rede, porque isso pode facilitar acesso não autorizado e atividade ofensiva.”

se estiver usando um modelo desbloqueado (por exemplo igorls/gemma-4-E4B-it-heretic-GGUF) seu teste deve ser executado.

I will use a standard aggressive scan (-A) across a broad range of common ports.

✓ Continue used the hexstrike nmap_advanced_scan tool

The Nmap scan provided excellent initial information!

Here is a summary of the findings from the reconnaissance phase:

Target: 192.168.15.169 **Operating System Detected:** Microsoft Windows XP SP2 or SP3 **Hostname:** [REDACTED] **W**

Open Ports and Services:

- **Port 21/tcp (FTP):** Running GNU Inetutils FTPd 1.3.2. Status shows it's waiting for a username.
- **Port 23/tcp (Telnet):** Running Openwall GNU/*/Linux telnetd.
- **Port 80/tcp (HTTP):** Running Apache httpd 2.2.11 (Win32) mod_jk/1.2.27. The title is "Site doesn't have a title"
- **Port 104/tcp (ACR-NEMA?):** Status is open, but the script execution failed.
- **Port 135/tcp (MSRPC):** Microsoft Windows RPC.
- **Port 139/tcp (NetBIOS-SSN):** Microsoft Windows NetBIOS-SSN.
- **Port 445/tcp (Microsoft-DS):** Windows XP microsoft-ds.
- **Port 512/tcp (Exec):** Open.

SMB Enumeration Findings:

- The SMB scan was successful, revealing the OS as **Windows XP (Windows 2000 LAN Manager)**.